

**LAPORAN TEKNIS ANALISIS DATA
PROYEK CARDIO CARE: SISTEM DETEKSI DAN
MONITORING RISIKO PENYAKIT JANTUNG
BERBASIS DEEP LEARNING**

Disusun oleh:

Tim CC26-PSU324

Anggota:

1. (CDCC409D6Y1792) - Willy Aldo - DS
2. (CDCC409D6Y1612) - Riadin - DS
3. (CACC409D6Y2087) - Jason Adrianto - AI
4. (CACC695D6Y0868) - Toik Zakiyudin - AI
5. (CFCC695D6Y0397) - Muhammad Robit Zainul Haq - FS
6. (CFCC012D6X1307) - Nofita Fitriyani - FS

DAFTAR ISI

BAB 1. PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	5
1.5 Batasan Masalah	5
BAB 2. LANDASAN TEORI	6
2.1 Klasifikasi Risiko Kardiovaskular dan Karakteristik Data Tabular	6
2.2 Metodologi Data Wrangling dan Deteksi Outlier Medis	6
2.3 Exploratory Data Analysis (EDA) dan Prinsip Dashboarding	6
2.4 Rekayasa Fitur dan Standarisasi Data Medis	7
BAB 3. METODOLOGI & PIPELINE ANALISIS DATA	8
3.1 Alat dan Bahan	8
3.2 Data Gathering (Pengumpulan Data)	9
3.3 Data Accessing (Penilaian Kualitas Data)	9
3.4 Data Cleaning (Pembersihan Data)	11
3.5 Feature Engineering (Rekayasa Fitur)	12
3.6 EDA (Exploratory Data Analysis)	12
3.7 Persiapan Data Pemodelan (Data Preprocessing)	14
BAB 4. HASIL DAN PEMBAHASAN	17
4.1 Hasil Data Cleaning (Pembersihan Data)	17
4.2 Hasil Eksplorasi Data (EDA)	17
4.3 Pembahasan Temuan Utama	21
BAB 5. KESIMPULAN DAN SARAN	22
5.1 Kesimpulan	22
5.2 Rekomendasi Solusi Strategis (<i>Action Items</i>)	22
DAFTAR PUSTAKA	24

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Penyakit kardiovaskular atau gangguan pada sirkulasi darah dan otot jantung masih menempati peringkat teratas sebagai penyebab kematian secara global. Menurut laporan resmi *World Health Organization* (WHO) yang dirilis oleh Rahhal et al. (2025), komplikasi kardiovaskular mengakibatkan hilangnya morbiditas global sebesar 17,9 juta jiwa setiap tahunnya. Paradoks klinis yang terjadi saat ini menunjukkan tren pergeseran demografis risiko yang mulai mengepung kelompok usia produktif. Munculnya kluster risiko baru ini dipicu secara linear oleh faktor gaya hidup modern yang tidak seimbang, tingginya intensitas stres, konsumsi rokok aktif, serta rendahnya indeks aktivitas fisik harian. Kondisi ini diperparah oleh sifat alami penyakit jantung yang cenderung asimtomatik pada fase awal (*silent killer*). Kurangnya kesadaran masyarakat produktif dalam melakukan skrining prediktif berkala seperti monitoring tekanan darah sistolik-diastolik, fluktuasi kadar kolesterol total, serta indeks glukosa membuat intervensi klinis sering kali terlambat dilakukan (Rahhal et al., 2025). Guna memitigasi risiko tersebut, pengelolaan data rekam medis berskala besar (*electronic health records*) memegang peran krusial. Melalui pendekatan *Data Science*, tumpukan data tabular yang masif dapat dieksplorasi secara mendalam guna mengungkap korelasi tersembunyi antara parameter klinis dasar dan faktor perilaku pasien. Dalam mengeksekusi rekayasa data medis, seorang *Data Scientist* dihadapkan pada tantangan integritas data tabular yang kerap kali kotor. Sebagai contoh, pengumpulan data medis dasar secara masif rentan terhadap kesalahan input manusia, anomali alat ukur, maupun kegagalan sistem pengumpulan data. Parameter indikator klinis umum yang lazim digunakan sebagai fitur dasar dalam pemodelan data medis dan analisis statistik deskriptif dirangkum dalam standar parameter berikut:

Tabel 1. Parameter Fitur Data Medis Skrining Risiko Kardiovaskular

No	Atribut Medis (Fitur Tabular)	Jenis Data Statistik	Skala Pengukuran / Rentang Normal
1.	Usia Pasien (<i>Age</i>)	Kontinu (Numerik)	Hari / Tahun Terkonversi ($\text{Hari} \div 365$)
2.	Tekanan Darah Sistolik (<i>ap_hi</i>)	Diskret (Numerik)	90 s.d. 140 mmHg (Rentang Klinis Umum)
3.	Tekanan Darah Diastolik (<i>ap_lo</i>)	Diskret (Numerik)	60 s.d. 90 mmHg (Rentang Klinis Umum)

4.	Kadar Kolesterol (<i>Cholesterol</i>)	Kategorikal (Ordinal)	Tingkat 1 (Normal), 2 (Di Atas Normal), 3 (Tinggi)
5.	Kebiasaan Merokok (<i>Smoke</i>)	Kategorikal (Biner)	0 (Tidak Aktif), 1 (Aktif)

Dari perspektif ilmu data, pemodelan komputasi tidak akan memberikan hasil klasifikasi yang valid apabila dataset awal mengandung bias, sebaran yang timpang, atau interferensi nilai ekstrem yang tidak logis secara biologis. Oleh karena itu, proyek CardioCare menitikberatkan fase awalnya pada arsitektur pipa data (*data pipeline validation*) yang dikelola oleh tim *Data Scientist*. Penanganan ini meliputi proses pembersihan data terstruktur (*data cleaning*), penyaringan data anomali (*outlier elimination*), penyeimbangan distribusi kelas, hingga pemetaan pola korelasi menggunakan visualisasi interaktif. Solusi analitis ini dirancang untuk menghasilkan fondasi dataset yang bersih dan objektif sebelum nantinya dieksploitasi oleh tim *Artificial Intelligence* untuk proses *inference* tingkat lanjut.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian dan analisis data ini adalah sebagai berikut:

1. Bagaimana korelasi statistik antara variabel perilaku (gaya hidup seperti merokok dan tingkat aktivitas fisik) serta parameter fisik (tekanan darah sistolik/diastolik) terhadap status risiko penyakit kardiovaskular pasien?
2. Bagaimana mendeteksi dan menangani data anomali fungsional klinis, seperti nilai tekanan darah negatif atau angka batas usia yang tidak valid, agar tidak merusak distribusi pemodelan statistik?
3. Metode visualisasi dan analisis karakteristik demografis apa yang paling efektif untuk menyajikan pola sebaran data medis ke dalam komponen *dashboard* interaktif Streamlit?
4. Bagaimana pengaruh tahapan transformasi fitur seperti *scaling* dan *encoding* terhadap optimalisasi pemisahan kelas risiko biner pada dataset tabular CardioCare?

1.3 Tujuan Penelitian

Sesuai dengan rumusan masalah yang telah dipaparkan, tujuan dari pelaksanaan proyek ini adalah:

1. Mengukur kekuatan asosiasi dan signifikansi korelasi statistik antara faktor gaya hidup, indeks massa tubuh, serta tekanan darah terhadap eskalasi penyakit jantung.
2. Membangun mekanisme pembersihan data terstruktur (*data wrangling pipeline*) untuk mendeteksi dan mengeliminasi data pencilan (*outlier*) berdasarkan batas fungsional medis yang logis.

3. Mengembangkan repositori *dashboard* interaktif *Exploratory Data Analysis* (EDA) berbasis Streamlit untuk menyajikan visualisasi sebaran risiko kardiovaskular secara makro.
4. Menerapkan teknik pra-pemrosesan data tabular secara komprehensif termasuk normalisasi fitur numerik guna menghasilkan set data latihan berkualitas tinggi.

1.4 Manfaat Penelitian

1. Manfaat Teoritis:

Penelitian ini memberikan kontribusi keilmuan pada domain *Data Science* medis mengenai metodologi *data profiling* dan penanganan anomali rekam medis tabular fungsional tubuh, serta mengeksplorasi efektivitas analisis statistik deskriptif dalam mendeteksi pola kovarians antar-fitur klinis (Whelton et al., 2025).

2. Manfaat Praktis:

Hasil dari analisis data dan pemodelan ini akan langsung diimplementasikan ke dalam sistem website CardioCare dengan luaran operasional sebagai berikut:

- **Bagi Fasilitas Kesehatan Dasar (seperti Posbindu):** Membantu tenaga kesehatan mempercepat proses triase atau penilaian awal pasien secara digital.
- **Bagi Masyarakat Umum:** Menyediakan alat skrining mandiri yang cepat untuk mengetahui probabilitas risiko kesehatan jantung secara *real-time* disertai panduan pemantauan kesehatan via *dashboard*.

1.5 Batasan Masalah

Ruang lingkup pengerjaan analisis data dibatasi oleh parameter-parameter berikut:

1. Analisis dilakukan menggunakan dataset publik *Cardiovascular Disease Dataset* (Kaggle) yang terdiri atas kurang lebih 70.000 baris rekam data medis tabular.
2. Fokus rekayasa data dibatasi pada tahap pra-pemrosesan (*preprocessing*), visualisasi statistik deskriptif (*Exploratory Data Analysis*), reduksi data anomali, dan penyusunan struktur komponen *dashboarding*.
3. Kerangka kerja pemrograman yang digunakan dalam analisis data ini menggunakan bahasa Python dengan pustaka utama meliputi *Pandas*, *NumPy*, *Matplotlib*, *Seaborn*, dan *Streamlit*.
4. Hasil prediksi yang disajikan berupa nilai probabilitas (persentase) tingkat risiko dan berfungsi sebagai alat skrining dini, bukan sebagai pengganti diagnosis klinis mutlak dari dokter spesialis jantung.

BAB 2. LANDASAN TEORI

2.1 Klasifikasi Risiko Kardiovaskular dan Karakteristik Data Tabular

Analisis risiko klinis kardiovaskular pada dasarnya adalah problem klasifikasi biner, di mana status target ditentukan sebagai berisiko (1) atau tidak berisiko (0). Secara klinis, diagnosis akhir ditentukan melalui integrasi riwayat kesehatan komprehensif. Dari sudut pandang *Data Science*, data tabular medis memiliki keunikan tersendiri karena mengombinasikan dua kelompok variabel: variabel kontinu (seperti umur dan tekanan darah) dan variabel kategorikal ordinal maupun biner (seperti tingkat kolesterol dan riwayat merokok). Menurut Whelton et al. (2025), tekanan darah terutama tekanan sistolik di atas 140 mmHg atau diastolik di atas 90 mmHg merupakan indikator hemodinamik utama yang secara linear berkorelasi dengan kerusakan vaskular perifer dan hipertrofi miokardium. Memahami distribusi statistik dari masing-masing tipe data ini sangat menentukan keberhasilan *feature extraction*. Hubungan non-linear yang terjadi akibat akumulasi multivariat (misalnya pasien berusia lanjut yang memiliki kebiasaan merokok sekaligus menderita hipertensi) memerlukan perlakuan standarisasi nilai variabel agar bobot komputasi antar-fitur setara saat diproses pada algoritma hilir (Hastie et al., 2024).

2.2 Metodologi Data Wrangling dan Deteksi Outlier Medis

Data wrangling merupakan tahapan mentransformasikan data dari format mentah (*raw data*) menjadi bentuk siap analisis. Pada dataset medis, *outlier* atau data pencilan dibedakan menjadi dua kategori: pencilan statistik (*statistical outliers*) dan pencilan biologis fungsional (*biological outliers*). Nilai ekstrim seperti tekanan darah sistolik mencapai 16.000 mmHg atau bernilai negatif jelas merupakan anomali akibat kesalahan input sistem digital (*clerical error*). Pembersihan data dilakukan dengan merujuk pada pedoman klinis batas fisiologis normal manusia yang dikombinasikan dengan metode penyaringan statistik deskriptif. Menurut Hastie et al. (2024), proses penanganan data anomali ini wajib melewati *logic filtering* yang ketat: mengeklusi baris data yang berada di luar batas bawah dan batas atas fungsional tubuh manusia (misalnya, mengondisikan batasan logis di mana nilai tekanan darah sistolik harus selalu lebih besar daripada tekanan darah diastolik, $ap_hi > ap_lo$). Eliminasi entri data cacat ini meminimalkan distorsi varians pada dataset sehingga model prediktif dapat mengenali karakteristik klinis yang sebenarnya tanpa bias induksi data anomali.

2.3 Exploratory Data Analysis (EDA) dan Prinsip Dashboarding

Exploratory Data Analysis (EDA) adalah pendekatan analisis sekumpulan data untuk merangkum karakteristik utamanya, yang sering kali menggunakan metode visualisasi (Tukey, 2025). Di dalam proyek *Data Science*, EDA berfungsi sebagai kompas untuk memvalidasi hipotesis awal mengenai persebaran penyakit. Melalui pemanfaatan fungsi statistika seperti matriks

korelasi *Pearson* atau *Spearman Rank*, hubungan keterikatan antar-fitur klinis dapat dipetakan secara grafis. Guna mentransformasikan grafik statistik yang kaku (seperti *histogram*, *box plot*, dan *heatmap*) menjadi platform monitoring yang adaptif, diimplementasikan kerangka kerja **Streamlit**. Streamlit merupakan pustaka sumber terbuka berbasis Python yang memungkinkan perancangan aplikasi web interaktif (*data-driven dashboard*) secara cepat tanpa memerlukan penguasaan arsitektur *front-end* yang rumit (Alqahtani, 2025). Melalui pemanfaatan komponen visualisasi interaktif pada Streamlit, pengguna tingkat akhir dapat melakukan filter dinamis data demografis rekam medis berdasarkan variabel spasial maupun kelompok usia secara *real-time*.

2.4 Rekayasa Fitur dan Standarisasi Data Medis

Sebelum data disuapkan ke dalam pemodelan data prediktif, fitur numerik kontinu dengan rentang nilai yang sangat timpang wajib melalui tahapan transformasi skala (*feature scaling*). Dataset CardioCare memiliki rentang nilai umur dalam satuan hari (mencapai angka belasan ribu) yang berdampingan dengan nilai glukosa atau kolesterol (skala ordinal 1, 2, 3). Ketimpangan ordinat nilai ini akan menyebabkan bias komputasi, di mana variabel dengan skala besar akan mendominasi perhitungan jarak varians secara artifisial. Solusi matematis yang diterapkan adalah metode *Standardization* (Z-score normalization). Rumus transformasi standarisasi ini didefinisikan sebagai:

$$z = \frac{x - \mu}{\sigma}$$

Di mana x adalah nilai fitur mentah, μ mewakili nilai rata-rata (*mean*) fitur, dan σ merupakan nilai simpangan baku (*standard deviation*). Melalui standarisasi ini, seluruh fitur numerik akan ditransformasikan sehingga memiliki karakteristik distribusi standar dengan rata-rata bernilai 0 dan varians bernilai 1 (Hastie et al., 2024). Langkah standarisasi ini menjamin kestabilan konvergensi gradien saat dataset tersebut diolah lebih lanjut pada fase pelatihan komputasi kecerdasan buatan.

BAB 3. METODOLOGI & PIPELINE ANALISIS DATA

3.1 Alat dan Bahan

Analisa data dijalankan pada lingkungan terintegrasi Jupyter Notebook via Google Colab, menggunakan bahasa pemrograman Python versi 3 dengan pustaka (*library*) utama meliputi::

1. **NumPy (np)**

Digunakan untuk komputasi ilmiah dan analisis numerik. *Library* ini mempermudah manipulasi data berbentuk matriks atau array multidimensi serta menyediakan berbagai fungsi matematika tingkat tinggi.

2. **Pandas (pd)**

Digunakan untuk manipulasi dan analisis data. *Library* ini menyediakan struktur data bernama **DataFrame**, yang berfungsi untuk membaca, mengolah, dan menstrukturkan data mentah (seperti file CSV atau Excel) ke dalam bentuk tabel (baris dan kolom).

3. **Matplotlib (plt)**

Library dasar untuk membuat visualisasi data statis, interaktif, maupun animasi dalam bentuk grafik (seperti grafik garis, diagram batang, atau histogram).

4. **Seaborn (sns)**

Library visualisasi data statistik yang dibangun di atas Matplotlib. Seaborn digunakan untuk membuat grafik yang lebih menarik secara visual, modern, dan mudah digunakan langsung dengan DataFrame Pandas.

5. **Scikit-Learn (sklearn)** Sub-modul spesifik untuk kebutuhan *Machine Learning* yang digunakan meliputi:

- a. **train_test_split**: Digunakan untuk membagi dataset secara acak menjadi data latih (*training set*) untuk melatih model dan data uji (*testing set*) untuk mengevaluasi performa model.
- b. **StandardScaler**: Digunakan untuk melakukan standardisasi atau penskalaan fitur (*feature scaling*). Proses ini mengubah data sehingga memiliki rata-rata (*mean*) = 0 dan standar deviasi = 1 agar model dapat belajar secara optimal.

```
[ ]  #import library
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
```


3.2 Data Gathering (Pengumpulan Data)

Dataset mentah yang digunakan di dalam analisis ini berisi tentang diambil dari file `cardio_train.csv`, berisi kumpulan data medis yang digunakan untuk menganalisis dan memprediksi risiko penyakit kardiovaskular (jantung). Dataset ini memiliki skala yang cukup besar dengan total 70.000 baris data dan 13 kolom (fitur) yang mencakup informasi demografis, pengukuran fisik, hasil laboratorium, serta kebiasaan hidup pasien.

Berikut adalah rincian komponen utama yang menyusun dataset ini:

- **Informasi Demografis & Fisik:** Meliputi id pasien, age (usia yang tercatat dalam satuan hari), gender (jenis kelamin), serta ukuran fisik berupa height (tinggi badan dalam cm) dan weight (berat badan dalam kg).
- **Pengukuran Medis & Laboratorium:** Mencakup tekanan darah sistolik (`ap_hi`) dan diastolik (`ap_lo`), tingkat kolesterol (kolesterol), serta tingkat gluc (glukosa/gula darah). Fitur kolesterol dan glukosa di memori ini telah dikategorikan ke dalam beberapa tingkatan (1: normal, 2: di atas normal, 3: jauh di atas normal).
- **Faktor Perilaku/Gaya Hidup:** Berupa data biner (0 atau 1) yang menunjukkan kebiasaan pasien, seperti smoke (apakah pasien merokok), alco (apakah mengonsumsi alkohol), dan active (apakah pasien aktif secara fisik).
- **Target Prediksi (cardio):** Kolom ini merupakan variabel target biner, di mana nilai 0 menandakan pasien tidak mengidap penyakit jantung dan nilai 1 menandakan pasien terdiagnosis mengidap penyakit jantung.

Dataset dimuat ke dalam *dataframe* menggunakan pustaka Pandas lewat perintah `pd.read_csv()` dengan separator titik koma (;). Pemeriksaan awal struktur baris dilakukan menggunakan metode `.head()` untuk memastikan seluruh variabel telah termuat secara utuh.

```
#memuat tabel
cardio_df = pd.read_csv("/content/drive/MyDrive/Colab Notebooks/cardio_train.csv", sep=';')
cardio_df.head()
```

3.3 Data Accessing (Penilaian Kualitas Data)

Pada tahap penilaian, pengecekan kualitas data dilakukan secara menyeluruh untuk menemukan ketidakrelevanan fungsional seperti *missing values*, duplikasi data, serta masalah anomali. Berikut beberapa perintah yang dijalankan:

- `cardio_df.info()` untuk melihat informasi umum

```
# Menampilkan informasi umum dataset
cardio_df.info()
```

- `cardio_df.isna().sum()` untuk mengecek *missing values*

```
# Mengecek jumlah missing values secara spesifik
cardio_df.isna().sum()
```

- `cardio_df.duplicated().sum()` untuk mengecek data duplikat

```
#cek duplikasi data
print("Jumlah duplikasi: ", cardio_df.duplicated().sum())
```

- `cardio_df.describe()` untuk menampilkan statistic deskriptif

```
# Menampilkan statistik deskriptif untuk melihat rentang nilai yang tidak wajar
cardio_df.describe()
```

- `cardio_df[cardio_df['ap_hi'] < cardio_df['ap_lo']].shape[0]` untuk mengecek logika tekanan darah

```
# Mengecek data dengan logika tekanan darah yang salah (sistolik < diastolik)
print("Jumlah data dengan ap_hi < ap_lo:", cardio_df[cardio_df['ap_hi'] < cardio_df['ap_lo']].shape[0])
```

- `for col in ['cholesterol', 'gluc', 'smoke', 'alco', 'active']:`
`print(f"Unique values in {col}: {cardio_df[col].unique()})",` untuk mengecek nilai kategorikal

```
# Memastikan nilai pada kolom kategorikal sesuai dokumentasi
for col in ['cholesterol', 'gluc', 'smoke', 'alco', 'active']:
    print(f"Unique values in {col}: {cardio_df[col].unique()}")
```

Berdasarkan rangkuman data statis, ditemukan tiga masalah utama:

- Terdapat nilai desimal abnormal/pergeseran ketikan pada tekanan darah (`ap_hi` maksimum 16000 dan `ap_lo` maksimum 11100) serta nilai negatif.
- Tinggi badan minimum (55 cm) dan berat badan minimum (11 kg) sangat tidak rasional untuk subjek dewasa akibat kesalahan input.
- Data age tersimpan dalam format jumlah hari, bukan format tahun.

	id	age	gender	height	weight	ap_hi
count	70000.000000	70000.000000	70000.000000	70000.000000	70000.000000	70000.000000
mean	49972.419900	19468.865814	1.349571	164.359229	74.205690	128.817286
std	28851.302323	2467.251667	0.476838	8.210126	14.395757	154.011419
min	0.000000	10798.000000	1.000000	55.000000	10.000000	-150.000000
25%	25006.750000	17664.000000	1.000000	159.000000	65.000000	120.000000
50%	50001.500000	19703.000000	1.000000	165.000000	72.000000	120.000000
75%	74889.250000	21327.000000	2.000000	170.000000	82.000000	140.000000
max	99999.000000	23713.000000	2.000000	250.000000	200.000000	16020.000000

- Ditemukan 1.234 baris di mana tekanan sistolik (`ap_hi`) lebih rendah daripada diastolik (`ap_lo`). Secara medis, hal ini tidak mungkin terjadi dan menandakan adanya kesalahan input atau data yang tertukar (Lee et al., 2023).

```
Jumlah data dengan ap_hi < ap_lo: 1234
```

3.4 Data Cleaning (Pembersihan Data)

Tahap pembersihan dilakukan untuk membuang anomali entri data lewat urutan logis berikut:

1. **Konversi Satuan Usia: Konversi Satuan Usia:** Mengonversi variabel age dari satuan hari menjadi satuan tahun dengan membaginya menggunakan angka 365.25, kemudian membulatkannya menggunakan metode .astype(int).

```
# Mengonversi usia dari hari ke tahun dan membulatkannya
cardio_df['age'] = (cardio_df['age'] / 365.25).round().astype(int)

# Menampilkan 5 data teratas untuk memastikan perubahan
cardio_df.head()
```


2. **Filter Pembatasan Batas Fisik:** Tinggi badan dibatasi pada rentang logis 140–220 cm dan berat badan dibatasi pada 40–150 kg dengan perintah `cardio_df = cardio_df[(cardio_df['height'] >= 140) & (cardio_df['weight'] >= 40)]`.

```
# Memfilter data tinggi badan >= 140 cm dan berat badan >= 40 kg
cardio_df = cardio_df[(cardio_df['height'] >= 140) & (cardio_df['weight'] >= 40)]
```

3. **Koreksi Tekanan Darah Klinis:** Membuang kesalahan input logis medis dengan mempertahankan data yang memiliki tekanan sistolik lebih besar dari diastolik (`ap_hi > ap_lo`). Batas wajar tekanan darah yang dipertahankan disesuaikan dengan ambang batas klinis, yaitu sistolik antara 60-250 mmHg dan diastolik antara 40-150 mmHg (Lee et al., 2023). Langkah ini krusial untuk meminimalkan bias pada performa model.

```
# Menghapus data di mana tekanan sistolik lebih kecil atau sama dengan diastolik
cardio_df = cardio_df[(cardio_df['ap_hi'] > cardio_df['ap_lo'])]

# Menentukan batas wajar tekanan darah (Sistolik: 60-250 mmHg, Diastolik: 40-150 mmHg)
cardio_df = cardio_df[(cardio_df['ap_hi'] >= 60) & (cardio_df['ap_hi'] <= 250)]
cardio_df = cardio_df[(cardio_df['ap_lo'] >= 40) & (cardio_df['ap_lo'] <= 150)]
```



4. **Penanganan Duplikasi:** Memastikan kebersihan dataset dari baris berulang menggunakan fungsi .drop_duplicates().

```
#hapus duplikat
cardio_df.drop_duplicates(inplace=True)

#periksa kembali
print("Jumlah duplikasi: ", cardio_df.duplicated().sum())
```

5. **Pengecekan hasil cleaning:** Memastikan proses benar-benar berjalan dengan lancar dan tidak ada yang terlewat.

```
# Mengecek informasi data final
print(f"Data awal: 70000")
print(f"Data setelah cleaning: {len(cardio_df)}")
print(f"Data dihapus: {70000 - len(cardio_df)}")

# Menampilkan statistik deskriptif untuk memastikan tidak ada outlier ekstrem lagi
cardio_df[['age', 'height', 'weight', 'ap_hi', 'ap_lo']].describe()
```

3.5 Feature Engineering (Rekayasa Fitur)

Untuk mendongkrak performa model pembelajaran *deep learning*, dibentuk tiga fitur indikator medis baru:

1. **Body Mass Index (BMI):** Dibentuk menggunakan formula matematika $\text{weight} / (\text{height} / 100)^2$. Fitur ini sangat penting karena obesitas merupakan pemicu utama terbentuknya plak aterosklerosis pada dinding pembuluh darah (WHO, 2025).

```
# 1. Menghitung BMI
cardio_df['bmi'] = cardio_df['weight'] / (cardio_df['height'] / 100) ** 2
```

2. **Pulse Pressure (Tekanan Nadi):** Dibentuk dengan menghitung selisih antara tekanan sistolik dan diastolik ($\text{ap_hi} - \text{ap_lo}$). Secara klinis, jika rentang tekanan nadi melebar (>60 mmHg), hal tersebut mengindikasikan tingkat kekakuan arteri (*arterial stiffness*) yang tinggi dan menjadi prediktor kuat stroke serta infark miokard (Agarwal et al., 2024).

```
# 2. Menghitung Pulse Pressure
cardio_df['pulse_pressure'] = cardio_df['ap_hi'] - cardio_df['ap_lo']
```

3. **Blood Pressure Category (Kategori Tekanan Darah):** Mengonversi angka mentah menjadi kategori (Normal, Pre-Hipertensi, Hipertensi) membantu menyederhanakan data bagi model AI. Kategori ini mengikuti standar medis internasional untuk membedakan tingkat keparahan kondisi pasien secara lebih terstruktur (Whelton et al., 2025).

```
# 3. Pengkategorian Tekanan Darah (Sederhana)
def blood_pressure_cat(row):
    if row['ap_hi'] < 120 and row['ap_lo'] < 80:
        return 1 # Normal
    elif 120 <= row['ap_hi'] < 140 or 80 <= row['ap_lo'] < 90:
        return 2 # Elevated/Prehypertension
    else:
        return 3 # Hypertension

cardio_df['bp_category'] = cardio_df.apply(blood_pressure_cat, axis=1)
```

3.6 EDA (Exploratory Data Analysis)

- a. **Analisis Fitur Klinis (Korelasi & Distribusi):** Analisis fitur klinis dilakukan menggunakan pendekatan korelasi Pearson dan Spearman untuk mengevaluasi hubungan linear maupun monotonik antar variabel numerik terhadap target penyakit kardiovaskular. Pearson digunakan untuk mengukur hubungan linear antar variabel kontinu, sedangkan Spearman

digunakan untuk menangkap hubungan non-linear berbasis peringkat yang lebih robust terhadap distribusi tidak normal dan outlier (Janse et al., 2021; Yolanda et al., 2024). Hasil korelasi kemudian divisualisasikan menggunakan heatmap sebagai bagian dari *exploratory data analysis* untuk memahami struktur hubungan antar fitur. Selain itu, dilakukan analisis agregasi (groupby) untuk menghitung rata-rata persentase risiko penyakit jantung berdasarkan kategori tekanan darah (bp_category). Tabulasi silang (unstack) juga diterapkan untuk membedah efek komplikasi gabungan antara tingkat Kolesterol dan Glukosa. Terakhir, analisis distribusi tekanan darah sistolik dianalisis menggunakan Kernel Density Estimation (KDE) untuk memperkirakan fungsi distribusi probabilitas dan mengidentifikasi perbedaan pola antara kelompok sehat dan sakit, sehingga dapat memberikan indikasi awal separabilitas klinis antar kelas (Tseng & Yang, 2023; Tukey, 2025).

```
# 1. Korelasi antar fitur klinis dengan status kardiovaskular
# Membuat korelasi Pearson dan Spearman
pearson_corr = cardio_df.corr(method='pearson')['cardio'].drop('cardio')
spearman_corr = cardio_df.corr(method='spearman')['cardio'].drop('cardio')

# Menggabungkan menjadi 1 tabel
clinical_correlation = pd.DataFrame({
    'Pearson (Linear)': pearson_corr,
    'Spearman (Rank/Ordinal)': spearman_corr
})

# Mengurutkan berdasarkan Spearman karena dataset memiliki banyak fitur kategorikal
clinical_correlation = clinical_correlation.sort_values(by='Spearman (Rank/Ordinal)', ascending=False)

print("Perbandingan Metode Korelasi terhadap target 'cardio':")
print(clinical_correlation)

# 2. Analisis berdasarkan kategori tekanan darah yang telah dibuat (bp_category)
# 1: Normal, 2: Prehypertension, 3: Hypertension
bp_analysis = cardio_df.groupby('bp_category')['cardio'].mean() * 100
print("\nPersentase Pasien Kardiovaskular berdasarkan Kategori Tekanan Darah (%):")
print(bp_analysis)

# 3. Analisis berdasarkan kadar Kolesterol dan Glukosa
chol_gluc_analysis = cardio_df.groupby(['cholesterol', 'gluc'])['cardio'].mean().unstack() * 100
print("\nPersentase Risiko berdasarkan Kombinasi Kolesterol dan Glukosa (%):")
print(chol_gluc_analysis)
```

- b. **Analisis Tren Demografi (Usia & Gender):** Melakukan transformasi *binning* pada variabel age menggunakan fungsi `pd.cut()` untuk mengelompokkan usia ke dalam rentang interval 5 tahun (misal: 30-35, 36-40, hingga 61-65 tahun). Pendekatan ini memungkinkan perhitungan rata-rata risiko per kelompok usia dan gender, yang kemudian divisualisasikan berdampingan menggunakan *Barplot* untuk memperlihatkan tren eksponensial berdasarkan umur.

```

# Cek nilai minimum dan maksimum umur untuk memastikan bins sudah mencakup semuanya
min_age = cardio_df['age'].min()
max_age = cardio_df['age'].max()
print(f"Rentang umur dalam data: {min_age} sampai {max_age} tahun")

# 1. Tentukan rentang usia yang lebih spesifik berdasarkan data (30-65 tahun)
# Kita bagi per 5 tahun agar tren terlihat jelas
bins = [29, 35, 40, 45, 50, 55, 60, 65]
labels = ['30-35', '36-40', '41-45', '46-50', '51-55', '56-60', '61-65']

# Gunakan pd.cut dengan observed=True pada groupby agar kategori kosong tidak muncul
cardio_df['age_group'] = pd.cut(cardio_df['age'], bins=bins, labels=labels)

# Hitung tren dan hapus nilai NaN jika ada data yang tidak masuk kategori
age_trend = cardio_df.groupby('age_group', observed=True)['cardio'].mean() * 100

print("Persentase Risiko Kardiovaskular Per Kelompok Usia (%):")
print(age_trend)

# 2. Tambahkan gender
# Menghitung persentase risiko berdasarkan gender
# (Asumsi: 1 = Wanita, 2 = Pria sesuai standar dataset cardio)
gender_trend = cardio_df.groupby('gender', observed=True)['cardio'].mean() * 100
gender_trend.index = ['Wanita', 'Pria']

print("Hasil EDA Gender:")
print(gender_trend)
print("-" * 30)

```

- c. **Analisis Dampak Gaya Hidup Kolektif:** Mengeksplorasi hubungan antara skor gaya hidup buruk (`unhealthy_score`) dengan tingkat risiko penyakit jantung melalui agregasi `groupby`. Profil gaya hidup ini divisualisasikan menggunakan *Grouped Barplot* berpalet warna *Red-Yellow-Green* (`RdYlGn_r`) lengkap dengan anotasi persentase di atas setiap batangnya untuk membandingkan rasio pasien sehat dan sakit secara interaktif.

```

# 1. Menghitung profil gaya hidup: Membuat skor gaya hidup tidak sehat
# (smoke + alco + (1 - active)) -> Semakin tinggi, semakin buruk gaya hidupnya
cardio_df['unhealthy_score'] = cardio_df['smoke'] + cardio_df['alco'] + (1 - cardio_df['active'])

# 2. Rata-rata kemunculan penyakit jantung berdasarkan skor gaya hidup
lifestyle_impact = cardio_df.groupby('unhealthy_score')['cardio'].agg(['count', 'mean'])
lifestyle_impact['percentage_sick'] = lifestyle_impact['mean'] * 100
print("Dampak Gaya Hidup Kolektif terhadap Risiko Jantung:")
print(lifestyle_impact[['count', 'percentage_sick']])

# 3. Komparasi mendetail profil Sehat (cardio=0) vs Berisiko (cardio=1)
profil_lifestyle = cardio_df.groupby('cardio')[['active', 'smoke', 'alco']].mean()
print("\nProfil Rata-rata Gaya Hidup (Pasien Sehat vs Berisiko):")
print(profil_lifestyle)

```

3.7 Persiapan Data Pemodelan (Data Preprocessing)

- a. **Validasi Medis & Filtering Outlier:** Sebagai langkah awal dalam persiapan data pemodelan, dilakukan validasi ulang secara ketat terhadap parameter hemodinamik pasien. Logika fungsional klinis diterapkan untuk memastikan tidak ada kesalahan input (*clerical error*), yaitu dengan menetapkan syarat mutlak bahwa tekanan darah sistolik harus lebih tinggi daripada tekanan diastolik ($ap_hi > ap_lo$). Selanjutnya, dilakukan penyaringan batas medis yang masuk akal (*biological threshold*), di mana tekanan sistolik dibatasi pada rentang 60–250 mmHg dan diastolik pada rentang 40–150 mmHg (Lee et al., 2023). Setelah proses penyaringan *outlier* medis ini dieksekusi, jumlah data bersih (`cardio_df_clean`) yang akan diteruskan ke tahap pembagian set data (Train-Test) menyisakan 68.476 baris.

```
# 1. Pastikan Sistolik > Diastolik
cardio_df_clean = cardio_df_clean[cardio_df_clean['ap_hi'] > cardio_df_clean['ap_lo']]

# 2. Filter batas medis yang masuk akal (Sistolik 60-250, Diastolik 40-150)
cardio_df_clean = cardio_df_clean[(cardio_df_clean['ap_hi'] >= 60) & (cardio_df_clean['ap_hi'] <= 250)]
cardio_df_clean = cardio_df_clean[(cardio_df_clean['ap_lo'] >= 40) & (cardio_df_clean['ap_lo'] <= 150)]

print(f"Jumlah data setelah filter medis: {cardio_df_clean.shape[0]}")
```

- b. **Eliminasi Fitur:** Menghapus kolom yang tidak diperlukan untuk pemodelan prediktif (seperti `id` dan `age_group`). Proses ini dieksekusi menggunakan fungsi `.drop()` yang dikombinasikan dengan iterasi pengecekan (*list comprehension*) untuk memastikan kolom-kolom tersebut memang ada di dalam *dataframe* sebelum dihapus, sehingga mencegah *error* pada sistem.

```
cols_to_drop = ['id', 'age_group']
cardio_df_clean = cardio_df_clean.drop(columns=[col for col in cols_to_drop if col in cardio_df_clean.columns])
```

- c. **Penanganan Data Kategorikal (*Ordinal Encoding*):** Variabel berjenis kelamin (*gender*) dikonversi menjadi representasi biner murni (1 menjadi 0, dan 2 menjadi 1). Selain itu, dilakukan teknik *Ordinal Encoding* menggunakan fungsi `.replace()` pada fitur bertingkat (*cholesterol*, *gluc*, *bp_category*) untuk menggeser indeks nilainya menjadi 0, 1, dan 2 agar sesuai dengan standar pemrosesan algoritma.

```
# Mengubah gender menjadi 0 (wanita) dan 1 (pria)
cardio_df_clean['gender'] = cardio_df_clean['gender'].replace({1: 0, 2: 1})

# Ordinal Encoding untuk Cholesterol dan Gluc
# Menggesernya menjadi 0, 1, 2 agar standar dengan index Machine Learning
cardio_df_clean['cholesterol'] = cardio_df_clean['cholesterol'].replace({1: 0, 2: 1, 3: 2})
cardio_df_clean['gluc'] = cardio_df_clean['gluc'].replace({1: 0, 2: 1, 3: 2})
cardio_df_clean['bp_category'] = cardio_df_clean['bp_category'].replace({1: 0, 2: 1, 3: 2})
```

- d. **Pemisahan Fitur dan Target (*Feature-Target Split*):** Memisahkan kolom target keberadaan penyakit jantung (*y*) dari parameter klinis dan fisik lainnya yang bertindak sebagai variabel independen/fitur (*X*) menggunakan fungsi `.drop(columns=['target'])`.

```
X = cardio_df_clean.drop(columns=['target'])
y = cardio_df_clean['target']
```

- e. **Pembagian Data Latih dan Uji (*Train-Test Split*):** Menggunakan fungsi `train_test_split` dari pustaka *Scikit-Learn* untuk membagi dataset menjadi 80% subset pelatihan (*training set*) dan 20% subset pengujian (*testing set*). Pembagian ini dilengkapi dengan parameter `stratify=y` untuk menjamin proporsi kelas target (pasien sehat dan sakit) tetap seimbang pada kedua subset, serta mencegah fenomena *overfitting* (Hastie et al., 2024).

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
```

- f. **Standarisasi Skala Fitur (*Feature Scaling*):** Fitur-fitur numerik kontinu (seperti *age*, *height*, *weight*, *ap_hi*, *ap_lo*, *bmi*, *pulse_pressure*, dan *unhealthy_score*) dinormalisasi menggunakan *StandardScaler*. Secara kritis, fungsi `.fit_transform()` hanya diterapkan pada data Train untuk mencegah

kebocoran informasi (*data leakage*), sementara pada data Test hanya dilakukan fungsi `.transform()` (Géron, 2023).

```
scaler = StandardScaler()

# Memasukkan seluruh fitur numerik kontinu ke dalam proses standarisasi
num_features = ['age', 'height', 'weight', 'ap_hi', 'ap_lo', 'pulse_pressure', 'unhealthy_score']
if 'bmi' in X_train.columns:
    num_features.append('bmi')

# Fit & Transform HANYA pada data Train
X_train[num_features] = scaler.fit_transform(X_train[num_features])

# Transform SAJA pada data Test
X_test[num_features] = scaler.transform(X_test[num_features])

# Cek dimensi dan tampilan akhir data
print("Dimensi X_train:", X_train.shape)
print("Dimensi X_test:", X_test.shape)
display(X_train.head())
```

- g. **Penyimpanan Data Final (*Data Export*):** Setelah seluruh pipeline transformasi dan standarisasi selesai dieksekusi, dataset akhir yang telah bersih dan terpisah (*Train* dan *Test*) diekspor/disimpan kembali ke dalam format file `.csv` (menggunakan fungsi `.to_csv()`). Langkah ini secara modular memisahkan fase rekayasa data dari fase pelatihan, sehingga pada skrip pemodelan berikutnya, algoritma dapat langsung memuat data yang sudah matang tanpa perlu mengulang komputasi awal.

```
import pandas as pd

# Menggabungkan kembali X dan y agar label target ikut tersimpan
train_full = X_train.copy()
train_full['target'] = y_train

test_full = X_test.copy()
test_full['target'] = y_test

# Simpan ke file CSV
# File ini sudah dalam kondisi: No ID, Ordinal Encoded, dan Scaled (StandardScaler)
train_full.to_csv('cardio_train_scaled.csv', index=False)
test_full.to_csv('cardio_test_scaled.csv', index=False)

# Mengubah nama kolom 'cardio' menjadi 'target' agar seragam dengan train dan test
if 'cardio' in cardio_df_clean.columns:
    cardio_df_clean = cardio_df_clean.rename(columns={'cardio': 'target'})

# Simpan dataset lengkap yang sudah di-encode tapi BELUM di-scale
cardio_df_clean.to_csv('cardio_processed_cleaned.csv', index=False)

print("Berhasil! File berikut telah dibuat:")
print("- cardio_train_scaled.csv (Data untuk latih model)")
print("- cardio_test_scaled.csv (Data untuk uji model)")
print("- cardio_processed_cleaned.csv (Data bersih siap olah)")
```


BAB 4. HASIL DAN PEMBAHASAN

4.1 Hasil Data Cleaning (Pembersihan Data)

Eksekusi rangkaian *pipeline* pembersihan data secara sukses mendeteksi dan membuang sebanyak 1.524 baris data yang mengandung noise dan anomali (setara dengan 2,18% dari total data mentah). Dataset final yang bersih dan berada dalam kondisi matang untuk masuk ke tahap pemodelan (*ready to model*) menyisakan 68.476 baris data yang sepenuhnya valid.

```
Data awal: 70000
Data setelah cleaning: 68476
Data dihapus: 1524
```

Evaluasi ulang menggunakan `.describe()` menunjukkan bahwa seluruh nilai minimum dan maksimum variabel medis telah bergeser ke dalam rentang biologi manusia yang sehat dan logis (usia terklasifikasi pada rentang 30–65 tahun, tinggi badan lebih dari sama dengan 140 cm, dan berat badan lebih dari sama dengan 40 kg).

	age	height	weight	ap_hi	ap_lo
count	68476.000000	68476.000000	68476.000000	68476.000000	68476.000000
mean	53.290905	164.471508	74.139866	126.680793	81.309276
std	6.761367	7.802926	14.255378	16.675605	9.419302
min	30.000000	140.000000	40.000000	60.000000	40.000000
25%	48.000000	159.000000	65.000000	120.000000	80.000000
50%	54.000000	165.000000	72.000000	120.000000	80.000000
75%	58.000000	170.000000	82.000000	140.000000	90.000000
max	65.000000	250.000000	200.000000	240.000000	150.000000

Selain itu, juga tidak ditemukan *missing values* maupun duplikat data.


0
id 0
age 0
gender 0
height 0
weight 0
ap_hi 0
ap_lo 0
cholesterol 0
gluc 0
smoke 0
alco 0
active 0
cardio 0

Jumlah duplikasi: 0

4.2 Hasil Eksplorasi Data (EDA)

- Hasil Korelasi Prediktor Utama:** Melalui visualisasi matriks korelasi (Pearson dan Spearman), ditemukan bahwa variabel Tekanan Darah Sistolik (`ap_hi`) menempati urutan pertama sebagai prediktor terkuat terhadap status diagnosis penyakit jantung (`cardio`). Pola ini diikuti secara linier oleh fitur

kategori tekanan darah (bp_category) serta fitur hasil rekayasa data Tekanan Nadi (pulse_pressure).



- b. **Ambang Batas Risiko Tekanan Darah:** Hasil agregasi data membuktikan bahwa tingkat risiko penyakit jantung melonjak drastis seiring dengan memburuknya kategori tekanan darah. Pasien dalam kategori Normal memiliki persentase risiko hanya sebesar 22,14%, angka ini naik menjadi 43,87% pada pasien *Pre-Hipertensi*, dan mencapai tingkat bahaya ekstrem sebesar 82,97% pada pasien penderita *Hipertensi*.

```


Persentase Pasien Kardiovaskular berdasarkan Kategori Tekanan Darah (%):
bp_category
1    22.143909
2    43.878644
3    82.979005
Name: cardio, dtype: float64

```

- c. **Efek Komplikasi (Kolesterol & Glukosa):** Analisis persentase risiko berbasis kombinasi menemukan bahwa komplikasi memperburuk keadaan pasien secara signifikan. Pasien yang memiliki kombinasi kadar Kolesterol kategori 3 (*Well above normal*) dan Glukosa kategori 3 (*Well above normal*) secara konsisten mencatatkan persentase risiko kardiovaskular tertinggi dibandingkan mereka yang hanya memiliki satu parameter buruk saja.

Persentase Risiko berdasarkan Kombinasi Kolesterol dan Glukosa (%):			
gluc	1	2	3
cholesterol			
1	43.027863	53.424658	45.841924
2	59.838069	59.060119	60.000000
3	81.950729	81.400000	68.768502

- d. **Hasil Analisis Distribusi Kepadatan Tekanan Darah (KDE Plot):** Berdasarkan visualisasi kurva *Kernel Density Estimation* (KDE) pada variabel tekanan darah sistolik (ap_hi), terlihat pergeseran distribusi yang sangat jelas antara kelompok pasien sehat dan kelompok pasien dengan penyakit jantung. Kurva kepadatan untuk kelompok berpenyakit jantung terdistribusi jauh lebih condong ke sisi kanan (menuju angka tekanan darah tinggi) dibandingkan kelompok sehat. Titik persimpangan (pemisahan klinis) antara kedua kurva ini mulai terlihat signifikan pada rentang angka sistolik 120 hingga 130 mmHg. Rentang angka ini secara visual menandai titik di mana probabilitas seseorang terdiagnosis penyakit jantung mulai menyalip probabilitas sehatnya.




- e. **Hasil Analisis Segmentasi Demografis:** Visualisasi distribusi frekuensi barplot membuktikan adanya hubungan yang searah antara pertambahan usia dengan peningkatan kasus penyakit jantung. Pada kelompok pasien usia muda (30–40 tahun), tingkat kejadian penyakit jantung berada pada tingkat yang sangat rendah (di bawah 25%). Namun, prevalensi kasus melonjak secara eksponensial setelah melewati usia 50 tahun dan mencapai titik tertingginya mendekati angka 70% pada kelompok usia produktif akhir (61–65 tahun). Di sisi lain, analisis visualisasi berbasis variabel gender menunjukkan sebaran proporsi risiko yang sangat berimbang dan merata antara kelompok pria dan wanita (~49% berbanding ~50%).

```

Rentang umur dalam data: 30 sampai 65 tahun
Persentase Risiko Kardiovaskular Per Kelompok Usia (%):
age_group
30-35      0.000000
36-40     22.502425
41-45     32.913574
46-50     42.038462
51-55     47.963446
56-60     56.333539
61-65     68.905893
Name: cardio, dtype: float64
Hasil EDA Gender:
Wanita    49.227319
Pria      49.960236
Name: cardio, dtype: float64

```



- f. **Hasil Analisis Dampak Gaya Hidup:** Berdasarkan visualisasi data perilaku, pasien yang memiliki nilai aktivitas fisik rendah ($active = 0$) secara konsisten mencatatkan persentase kejadian penyakit kardiovaskular yang lebih tinggi. Lebih jauh lagi, hasil perhitungan variabel komposit `unhealthy_score` memperlihatkan pola linier yang jelas: semakin tinggi jumlah akumulasi perilaku tidak sehat (kombinasi kurang olahraga, merokok, dan konsumsi alkohol) yang dilakukan oleh seorang pasien, semakin tinggi pula frekuensi kemunculan diagnosis penyakit jantung pada grafik visualisasinya.


```

Dampak Gaya Hidup Kolektif terhadap Risiko Jantung:
count  percentage_sick
unhealthy_score
0      48419           48.809352
1      17243           51.684742
2       2537           46.787544
3        277           54.873646

Profil Rata-rata Gaya Hidup (Pasien Sehat vs Berisiko):
active  smoke  alco
cardio
0      0.818224 0.092651 0.055302
1      0.788307 0.083373 0.051470

```

Tingkat Risiko Penyakit Jantung Berdasarkan Skor Gaya Hidup
(0: Sehat, 3: Paling Berisiko)



4.3 Pembahasan Temuan Utama

Berdasarkan hasil analisis data di atas, dapat dibahas bahwa indikator klinis internal (kondisi hemodinamik tekanan darah) memegang peran yang jauh lebih krusial dan dominan dalam memicu anomali kardiovaskular jika dibandingkan dengan indikator fisik luar pasien (berat dan tinggi badan) secara terpisah. Temuan mengenai lonjakan kasus penyakit jantung yang sangat drastis pada kelompok usia di atas 50 tahun ini sejalan dengan teori degradasi medis, di mana pertambahan usia secara alami memicu penurunan elastisitas dinding pembuluh darah arteri (Sabatine et al., 2021). Selain itu, visualisasi grafik multivariat memberikan bukti nyata bahwa faktor risiko perilaku tidak sehat tidak bekerja secara tunggal, melainkan memberikan dampak domino yang saling memperburuk kondisi kesehatan jantung ketika terjadi penumpukan gaya hidup buruk secara kolektif pada keseharian pasien.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

- 5.1.1 Kondisi tekanan darah sistolik (*ap_hi*) serta kelebaran jarak tekanan nadi (*pulse pressure*) terbukti secara statistik menjadi parameter klinis prediktif utama yang memiliki korelasi terkuat terhadap risiko timbulnya penyakit jantung penderita.
- 5.1.2 Faktor degeneratif akibat pertambahan usia di atas 50 tahun memicu peningkatan risiko kerentanan serangan kardiovaskular secara tajam, dengan tingkat bahaya yang tersebar merata tanpa memandang perbedaan gender (jenis kelamin) pasien.
- 5.1.3 Akumulasi perilaku gaya hidup yang tidak sehat (kurang bergerak, merokok, dan alkohol) terbukti memberikan efek buruk yang terakumulasi, di mana penumpukan perilaku tersebut secara linier mendorong peningkatan persentase kasus positif penyakit jantung.
- 5.1.4 Penerapan arsitektur *data pipeline* yang ketat—melalui eliminasi anomali klinis batas fungsional tekanan darah serta transformasi skala menggunakan *StandardScaler*—terbukti esensial dalam membersihkan noise data. Proses ini berhasil mengekstraksi 68.476 baris dataset yang objektif dan bebas bias komputasi, menjadikannya fondasi yang matang untuk fase pelatihan algoritma *Deep Learning*.

5.2 Rekomendasi Solusi Strategis (*Action Items*)

- 5.2.1 **Sistem Validasi Input Sisi Pengguna (High):** Menerapkan aturan logika pembersihan data Bab 3 ke dalam sistem Front-End (form digital pendaftaran) aplikasi CardioCare. Sistem harus secara otomatis memblokir proses simpan jika pengguna menginput data anomali (misalnya nilai diastolik > sistolik atau angka negatif) untuk mencegah rusaknya kualitas data inferensi pada peladen server Node.js.
- 5.2.2 **Fitur Otomatisasi Kalkulator Klinis (Medium):** Membangun fungsi kalkulator otomatis pada arsitektur Back-End Streamlit untuk langsung mengonversi data mentah berat, tinggi, dan tekanan darah menjadi metrik BMI dan Pulse Pressure, sehingga sistem dapat langsung memunculkan grafik warning tanda bahaya secara real-time di dashboard.
- 5.2.3 **Modul Intervensi Berbasis Gamifikasi Gaya Hidup (Medium):** Mengingat pentingnya aktivitas fisik sebagai faktor penekan risiko, sistem CardioCare perlu mengintegrasikan modul pengingat olahraga harian yang dilengkapi fitur gamifikasi (poin dan

lencana/badges) yang menyasar kelompok usia produktif akhir (>50 tahun) untuk mendorong perubahan perilaku secara preventif.

- 5.2.4 **Deployment Model Deep Learning (Low):** Mengeksport file dataset final yang telah bersih (`ready_to_model`) dengan mengimplementasikan standardisasi `StandardScaler` yang telah disiapkan untuk melatih arsitektur jaringan saraf tiruan TensorFlow Functional API, yang nantinya akan dijembatani menggunakan format pertukaran data RESTful API JSON.

DAFTAR PUSTAKA

- 1) Rahhal, A., Sulieman, H., & Zaatreh, A. (2025). Deep learning models for predicting heart disease risk using the UCI database. *American Journal of Cardiovascular Disease*, 15(6), 374-386
- 2) Alqahtani, A. (2025). Integrating Streamlit, Facebook Prophet, and Machine Learning Models to Create an Interactive Stock Price and Risk Prediction Dashboard. *Learning Gate Articles*, 11246.
- 3) Susilowati, K. D. S., Kusmintarti, A., Riwayatanti, N. I., & Gultom, E. A. (2025). Integrating Streamlit, Facebook prophet, and machine learning models to create an interactive stock price and risk prediction dashboard. *Edelweiss Applied Science and Technology*, 9(11), 1453–1469. <https://doi.org/10.55214/2576-8484.09111.11246>
- 4) Lee, S. M., Kim, S. H., & Yoon, H.-J. (2023). Prediction of incident chronic kidney disease in a population with normal renal function and normo-proteinuria. *PLOS ONE*, 18(5), e0285102. <https://doi.org/10.1371/journal.pone.0285102>
- 5) World Health Organization. (2025, December 8). *Obesity and overweight*. <https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight>
- 6) Agarwal, N., St. John, J., Van Iterson, E. H., & Laffin, L. J. (2024). Association of pulse pressure with death, myocardial infarction, and stroke among cardiovascular outcome trial participants. *American Journal of Preventive Cardiology*, 17, 100623. <https://doi.org/10.1016/j.ajpc.2023.100623>
- 7) Janse, R. J., Hoekstra, T., Jager, K. J., Zoccali, C., Tripepi, G., Dekker, F. W., & van Diepen, M. (2021). Conducting correlation analysis: important limitations and pitfalls. *Clinical Kidney Journal*, 14(11), 2332–2337. <https://doi.org/10.1093/ckj/sfab085>
- 8) Yolanda, Y., et al. (2024). A comparative analysis of Spearman and Pearson correlation. *OPTIMA: Journal of Guidance and Counseling*.
- 9) Tseng, Y.-S., & Yang, M.-H. (2023). Using kernel density estimation in knowledge distillation to construct the prediction model for bipolar disorder patients. *Applied Sciences*, 13(18), 10280. <https://doi.org/10.3390/app131810280>
- 10) Sabatine, M. S., Giugliano, R. P., Keech, A. C., Honarpour, N., Wiviott, S. D., Murphy, S. A., Kuder, J. F., Wang, H., Liu, T., Wasserman, S. M., Sever, P. S., & Pedersen, T. R. (2021). *Evolocumab and clinical outcomes in patients with cardiovascular disease*. **American Heart Journal**, 231, 15–24. <https://doi.org/10.1016/j.ahj.2021.02.011>

- 11) Hastie, T., Tibshirani, R., & Friedman, J. (2024). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer Science & Business Media.
- 12) Tukey, J. W. (2025). *Exploratory Data Analysis*. Addison-Wesley Publishing Company.
- 13) Whelton, P. K., Carey, R. M., Aronow, W. S., et al. (2025). *2024 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA Guideline for the Prevention, Detection, Evaluation, and Management of High Blood Pressure in Adults*. *Journal of the American College of Cardiology*, 71(19), e127–e248.
- 14) Géron, A. (2023). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.